

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA CÔNG NGHỆ THÔNG TIN



Môn học: Trắc quan hóa dữ liệu
Lớp: 23HTTT2

BÁO CÁO ĐỒ ÁN LÝ THUYẾT
Data Profiling & Data Abstraction & Task Abstraction

Giáo viên hướng dẫn

Tiết Gia Hồng
Nguyễn Trường Sơn
Phạm Minh Tú

—o0o—

Sinh viên

23127001 - Nguyễn Lê Quan Anh
23127006 - Trần Nguyễn Khải Luân
23127011 - Lê Anh Duy
23127179 - Nguyễn Bảo Duy
23127199 - Trần Gia Huy

Thành phố Hồ Chí Minh, tháng 3 năm 2026

MỤC LỤC

DATA PROFILING	6
1. Mục tiêu và phạm vi	6
1.1 Quy ước chung	6
2. Phiên bản dữ liệu (raw → selected → clean)	6
3. Profiling và chất lượng dữ liệu (tổng quan)	7
3.1 Quy mô dữ liệu ban đầu	7
3.2 Vấn đề chất lượng quan trọng và tác động phân tích	7
3.3 Mức sẵn sàng của dữ liệu không gian (GeoJSON)	7
4. Quy trình làm sạch dữ liệu	8
5. Tóm tắt dữ liệu sau làm sạch	8
5.1 Quy mô sau làm sạch	8
5.2 Thuộc tính trọng yếu được giữ	8
6. Kết luận profiling	9
6.1 Dữ liệu khả dụng cho phân tích	9
6.2 Liên kết chất lượng dữ liệu -> quyết định phân tích	9
6.3 Kết luận phạm vi bài toán	9
DATA ABSTRACTION	10
1. Dataset Abstraction	10
2. Attribute Abstraction	10
2.1 Thuộc tính – listings_clean	10
2.2 Thuộc tính – calendar_clean	11
2.3 Thuộc tính – reviews_clean	12
2.4 Thuộc tính – neighbourhoods.geojson	12
3. Data Relationship & Structure	13
3.1 Cardinality	13
3.2 Spatial Join	13
3.3 Hierarchical Attributes	13
4. Derived Attributes	13
5. Data Abstraction Summary	13
TASK ABSTRACTION	15
1. Domain Tasks (User Stories)	15
Task 1 – Thị trường & phân bố	15
Task 2 – Phân tích tỷ lệ lấp đầy theo thời gian	15
Task 3 – Cấu trúc nguồn cung và sức chứa	15
Task 4 – Chỉ số chất lượng và đánh giá khách hàng	15
Task 5 – Phân bố mức giá theo khu vực	15
Task 6 – Bản đồ Giá Bất thường & Giá trị Thực	16
Task 7 – Hiệu quả Chi phí lưu trú	16

Task 8 – Phân tích Mùa vụ và Cơ hội Đặt phòng	16
Task 9 – Phân tích Danh mục Chủ nhà	16
Task 10 – Trải nghiệm khách hàng	16
2. Task Abstraction	17
2.1 Domain Task 1 – Thị trường và phân bố	17
Analyze	17
Search	17
Query	17
Summary	17
2.2 Domain Task 2 – Phân tích tỷ lệ lấp đầy theo thời gian	17
Analyze	17
Search	17
Query	17
Summary	17
2.3 Domain Task 3 – Cấu trúc nguồn cung và sức chứa	17
Analyze	17
Search	18
Query	18
Summary	18
2.4 Domain Task 4 – Chỉ số chất lượng và đánh giá khách hàng	18
Analyze	18
Search	18
Query	18
Summary	19
2.5 Domain Task 5– Phân bố giá theo khu vực	19
2.6 Domain Task 6 – Bản đồ giá bất thường và giá trị thực	19
2.7 Domain Task 7 – Hiệu quả chi phí lưu trú	20
2.8 Domain Task 8 – Phân tích mùa vụ và cơ hội đặt phòng	20
2.9 Domain Task 9 – Phân tích danh mục chủ nhà	21
2.10 Domain Task 10 – Trải nghiệm khách hàng	21
Appendix - Bảng Profiling Chi Tiết	22
A.1 Bảng kiểm tra tính hợp lệ (regex/rule)	22
A.2 Bảng thống kê mô tả số (raw selected)	22
A.3 Bảng hai chiều theo từng thuộc tính (raw)	23
A.4 Bảng mẫu định dạng phổ biến (top patterns)	24
A.5 Bảng hồ sơ ngoại lệ (IQR)	24
A.6 Bảng phân tích giá trị thiếu	24
A.7 Bảng ví dụ bản ghi lỗi minimum_nights > maximum_nights	25
A.8 Bảng quyết định làm sạch (cleaning decision)	25
A.9 Bảng tổng quan chỉ số của file GeoJSON	26
A.10 Bảng kiểm tra tọa độ và bbox	27

A.11 Bảng coverage join theo neighbourhood	27
A.12 Bảng quy mô giảm sau làm sạch	27
A.13 Bảng toàn vẹn khóa sau làm sạch	28
A.14 Bảng occupancy theo tháng	28
A.15 Phân loại toàn bộ 28 thuộc tính được phân tích	28

DATA PROFILING

1. Mục tiêu và phạm vi

- **Dữ liệu đầu vào gồm 4 nguồn:** `listings`, `calendar`, `reviews`, `neighbourhoods.geojson`.
- **Mục tiêu nghiệp vụ:**
 - Task 1: Phân tích tổng quan thị trường và không gian (Market Overview & Spatial Distribution).
 - Task 2: Phân tích xu hướng theo thời gian (Temporal Trends).
- **Trọng tâm báo cáo:** Nêu rõ logic đánh giá dữ liệu (profiling) → định hướng làm sạch → cấu trúc dữ liệu để vẽ biểu đồ.

1.1 Quy ước chung

Để bài toán dễ theo dõi, thay vì dùng toàn bộ hàng chục cột dữ liệu gốc, chúng ta chỉ lấy ra các cột thật sự mang ý nghĩa:

- **Với Task 1 (Thị trường & Không gian):** Cần trả lời câu hỏi “Bán loại phòng gì, ở đâu, giá bao nhiêu?”. Do đó, `price` (giá) là thước đo chính, `room_type` (loại phòng) để phân nhóm, còn `neighbourhood` (khu vực) và `latitude/longitude` (tọa độ) dùng để chấm lên bản đồ.
- **Với Task 2 (Xu hướng thời gian):** Lẽ ra ta sẽ xem giá thay đổi thế nào qua các tháng. Tuy nhiên, vì phát hiện cột giá theo ngày (`calendar.price`) bị bỏ trống 100%, nên ta đổi sang quan sát tỷ lệ cư trú. Hai cột `date` và `available` (trạng thái phòng) trở thành cột lõi để vẽ nên biểu đồ mùa vụ.

2. Phiên bản dữ liệu (raw → selected → clean)

Phiên bản	Ý nghĩa	Dùng cho bước nào
<code>raw</code>	Dữ liệu gốc sau khi nạp file	Kiểm tra hiện trạng và phát hiện lỗi chính
<code>selected</code>	Tập con thuộc tính phục vụ profiling theo task	Đo lường chất lượng trên biến trọng yếu
<code>clean</code>	Dữ liệu sau pipeline làm sạch và kiểm tra toàn vẹn	Phân tích, tổng hợp KPI, thiết kế biểu đồ

Quy ước sử dụng trong báo cáo:

- Profiling chủ yếu đọc trên `raw/selected` để nhận diện vấn đề (đọc ở phần phụ lục).
- Phân tích và dashboard dùng `*_clean` để đảm bảo nhất quán và khả năng tái lập.

3. Profiling và chất lượng dữ liệu (tổng quan)

3.1 Quy mô dữ liệu ban đầu

Dataset	Rows (raw)	Cột profiling chính
Listings	36,353	13
Calendar	13,268,858	10
Reviews	1,000,870	3
GeoJSON (neighbourhoods)	233 features	2 thuộc tính vùng chính

3.2 Vấn đề chất lượng quan trọng và tác động phân tích

Chú thích tra cứu bảng chi tiết (Appendix):

- **Kiểm tra tính hợp lệ**: xem Bảng A.1.
- **Thống kê mô tả số**: xem Bảng A.2.
- **Cấu trúc dữ liệu theo thuộc tính**: xem Bảng A.3.
- **Mẫu định dạng**: xem Bảng A.4.
- **Hồ sơ ngoại lệ (IQR)**: xem Bảng A.5.
- **Bảng giá trị thiếu**: xem Bảng A.6.
- **Ví dụ bản ghi lỗi **minimum_nights > maximum_nights****: xem Bảng A.7.
- ****calendar.price** thiếu 100% (source-missing)**: không thể triển khai xu hướng giá theo thời gian.
- ****listings.reviews_per_month** và **listings.review_scores_rating** thiếu theo ngữ nghĩa (MAR)**: gắn với listing chưa có review, không nội suy cưỡng bức.
- **Tồn tại mâu thuẫn logic **minimum_nights > maximum_nights** trong calendar raw**: cần xử lý trước khi tổng hợp theo thời gian.
- ****maximum_nights** có giá trị cực đại bất thường (2,147,483,647)**: cần kiểm soát khi tóm tắt ràng buộc đặt phòng.

Ví dụ lỗi dữ liệu tiêu biểu:

1. ****calendar.price****: thiếu toàn bộ -> loại khỏi mọi phân tích giá theo ngày/tháng.
2. ****minimum_nights > maximum_nights****: biểu hiện mâu thuẫn nghiệp vụ -> vô hiệu cặp trường nights ở bản ghi lỗi.

3.3 Mức sẵn sàng của dữ liệu không gian (GeoJSON)

Chú thích tra cứu bảng chi tiết (Appendix):

- **Tổng quan chỉ số của file GeoJSON**: xem Bảng A.9.
- **Kiểm tra tọa độ/bbox**: xem Bảng A.10.
- **Coverage join theo **neighbourhood****: xem Bảng A.11.
- ****n_features=233, n_neighbourhood=230, n_neighbourhood_group=5****.
- **Coverage join dựa theo **neighbourhood****: match 222, listing-only 0, GeoJSON-only 8.

- Ý nghĩa: đủ điều kiện cho point map hoặc choropleth;

4. Quy trình làm sạch dữ liệu

1. **Standardize**: chuẩn hóa kiểu dữ liệu (giá, ngày, nhãn availability) và tạo biến thời gian mới (ngày, tháng).
2. **Deduplicate**: loại trùng theo mức độ chi tiết của từng bảng (`id`, `listing_id-date`, review event).
3. **Handle missing**: giữ missing có ý nghĩa nghiệp vụ (các trường về reviews), loại hoặc bỏ biến thiếu hoàn toàn (`calendar.price` với missing 100%).
4. **Remove invalid/inconsistent**: loại bản ghi không hợp lệ, xử lý mâu thuẫn `min > max`, lọc orphan để đảm bảo 2 bảng hợp lại là 1-n.
5. **Outlier policy**: không xóa outlier giá, gán cờ để phân tích thêm theo bối cảnh thị trường.

Chú thích tra cứu bảng quyết định làm sạch chi tiết: xem Bảng A.8.

5. Tóm tắt dữ liệu sau làm sạch

5.1 Quy mô sau làm sạch

Dataset	Clean rows	Clean cols	Vai trò phân tích
<code>listings_clean</code>	21,415	14	Bảng số liệu chính dạng cho thị trường/không gian
<code>calendar_clean</code>	7,816,487	11	Bảng số liệu chính theo thời gian cho tỷ lệ lấp đầy (occupancy/phòng không trống) hoặc khả dụng
<code>reviews_clean</code>	787,325	3	Tín hiệu hỗ trợ chất lượng/hoạt động

Chú thích tra cứu bảng hậu làm sạch chi tiết (Appendix):

- **Quy mô giảm theo pipeline**: xem Bảng A.12.
- **Toàn vẹn khóa sau làm sạch**: xem Bảng A.13.

5.2 Thuộc tính trọng yếu được giữ

- **Không gian**: `neighbourhood_group_cleansed`, `neighbourhood_cleansed`, `latitude`, `longitude`.
- **Thời gian**: `date`, `year`, `month`.
- **Measure chính**: `price` (listings), `is_available`, `is_booked`, `review_scores_rating`, `reviews_per_month`, `number_of_reviews`.
- **Khóa**: `listings.id`, `calendar.listing_id`, `reviews.listing_id`.

6. Kết luận profiling

6.1 Dữ liệu khả dụng cho phân tích

- Khả dụng: `listings_clean`, `calendar_clean`, `reviews_clean`, `neighbourhoods.geojson`.
- Không khả dụng theo mục tiêu ban đầu: temporal price từ `calendar.price` do thiếu 100%.

6.2 Liên kết chất lượng dữ liệu -> quyết định phân tích

- Vì `calendar.price` không dùng được, Task 2 chuyển từ xu hướng giá theo thời gian sang xu hướng lấp đầy/khả dụng (xem Bảng A.6 và A.8).
- Vì missing review fields mang ý nghĩa nghiệp vụ, giữ missing để tránh làm méo diễn giải chất lượng listing (xem Bảng A.6, A.8).
- Vì có mâu thuẫn và outlier nghiệp vụ, pipeline làm sạch áp dụng nguyên tắc sửa bằng cách đánh dấu thay vì xóa (xem Bảng A.5, A.7, A.8).

6.3 Kết luận phạm vi bài toán

- Giữ Task 1 (market + spatial) trên dữ liệu clean.
- Giữ Task 2 theo lấp đầy/khả dụng.
- Loại xu hướng giá theo thời gian trên dữ liệu hiện có.

Phản tiếp theo chuyển từ bằng chứng chất lượng dữ liệu sang đặc tả mô hình dữ liệu và quy tắc tổng hợp dùng cho dashboard.

DATA ABSTRACTION

1. Dataset Abstraction

Dataset	Dataset type	Granularity (Item)	Data availability	Vai trò trong mô hình
listings_clean	Table (Entity table – snapshot)	1 dòng = 1 listing	Static	Bảng fact chính cho phân tích thị trường & không gian
calendar_clean	Table (Temporal event table)	1 dòng = 1 listing–ngày	Temporal (time-varying)	Fact chính cho phân tích xu hướng theo thời gian
reviews_clean	Table (Event + text)	1 dòng = 1 review	Temporal	Tín hiệu hỗ trợ về chất lượng & hoạt động
neighbourhoods.geojson	Spatial dataset (polygon layer)	1 feature = 1 neighbourhood	Static	Lớp tham chiếu không gian cho bản đồ

2. Attribute Abstraction

2.1 Thuộc tính – [listings_clean](#)

Attribute	Type (Q/O/C)	Direction	Discrete / Continuous	Role
id	C	Nominal	Discrete	Key (PK)
host_id	C	Nominal	Discrete	Key (FK)
neighbourhood_group_cleansed	C	Nominal	Discrete	Dimension (spatial – cấp quận)

Attribute	Type (Q/O/C)	Direction	Discrete / Continuous	Role
neighbourhood_cleaned	C	Nominal	Discrete	Dimension (spatial – join GeoJSON)
latitude	Q	Sequential	Continuous	Spatial coordinate (Y)
longitude	Q	Sequential	Continuous	Spatial coordinate (X)
room_type	C	Nominal	Discrete	Dimension (category)
price	Q	Sequential	Continuous	Measure (financial)
availability_365	Q	Sequential	Discrete	Measure (availability)
accommodates	Q	Sequential	Discrete	Measure (capacity)
number_of_reviews	Q	Sequential	Discrete	Measure (activity)
reviews_per_month	Q	Sequential	Continuous	Measure (rate)
review_scores_rating	Q	Sequential	Continuous	Measure (quality signal)

2.2 Thuộc tính – calendar_clean

Attribute	Type	Direction	Discrete / Continuous	Role
listing_id	C	Nominal	Discrete	Key (FK)
date	O	Sequential	Discrete	Temporal dimension
available	C	Nominal	Discrete	Raw state

Attribute	Type	Direction	Discrete / Continuous	Role
minimum_nights	Q	Sequential	Discrete	Constraint
maximum_nights	Q	Sequential	Discrete	Constraint
is_available	C	Nominal	Discrete	Derived state
is_booked	Q	Sequential	Discrete	Measure (occupancy proxy)
year	O	Sequential	Discrete	Time aggregation
month	O	Cyclic	Discrete	Time aggregation (seasonality)

2.3 Thuộc tính – reviews_clean

Attribute	Type	Direction	Discrete / Continuous	Role
listing_id	C	Nominal	Discrete	Key (FK)
date	O	Sequential	Discrete	Temporal dimension
comments	C	Nominal	Discrete	Text attribute

2.4 Thuộc tính – neighbourhoods.geojson

Attribute	Type	Direction	Discrete / Continuous	Role
neighbourhood	C	Nominal	Discrete	Spatial key
neighbourhood_group	C	Nominal	Discrete	Spatial grouping

3. Data Relationship & Structure

3.1 Cardinality

Với **id** trong bảng listings là khóa chính, các **listing_id** ở các bảng còn lại sẽ là khóa ngoại, tham chiếu đến bảng listings.

- listings (1) → (n) calendar
- listings (1) → (n) reviews

3.2 Spatial Join

- listings.neighbourhood_cleansed → geojson.neighbourhood

3.3 Hierarchical Attributes

- Không gian (spatial hierarchy): neighbourhood_group_cleansed → neighbourhood_cleansed.
- Thời gian (temporal hierarchy): year → month → date.

Hai cấu trúc phân cấp này là cơ sở để roll-up/drill-down nhất quán khi tổng hợp số liệu trên dashboard.

4. Derived Attributes

Attribute	Definition	Purpose
is_available	map từ available	Chuẩn hóa trạng thái
is_booked	1 - is_available	Đo occupancy
year, month	extract từ date	Time aggregation
price_is_outlier	IQR flag	Robust analysis
occupancy_rate_pct	mean(is_booked)	KPI theo thời gian

Ghi chú: occupancy_rate_pct: số phòng không trống, được tính bằng số phòng không trống / tổng số phòng

5. Data Abstraction Summary

- Dữ liệu được tổ chức thành:
 - Entity (listings)
 - Temporal events (calendar, reviews)
 - Spatial layer (GeoJSON)

- Phân tách rõ:
 - **Dimension** (space, time, category)
 - **Measure** (price, occupancy, rating)
- Hỗ trợ trực tiếp cho:
 - Spatial analysis (map)
 - Distribution analysis (price)
 - Temporal trend (occupancy)
 - Hierarchical aggregation theo không gian và thời gian

TASK ABSTRACTION

1. Domain Tasks (User Stories)

Task 1 – Thị trường & phân bố

Người dùng muốn hiểu:

- Giá phân bố như thế nào theo khu vực
- Loại phòng nào chiếm ưu thế
- Khu vực nào đắt / rẻ bất thường

Task 2 – Phân tích tỷ lệ lấp đầy theo thời gian

Người dùng muốn:

- Quan sát occupancy theo tháng
- Nhận diện mùa cao / thấp điểm
- So sánh xu hướng theo thời gian

Task 3 – Cấu trúc nguồn cung và sức chứa

Người dùng muốn hiểu:

- Cấu trúc nguồn cung trên thị trường Airbnb NYC theo loại phòng, sức chứa và khu vực.
- Để xác định phân khúc nào đang chiếm ưu thế và khu vực nào phù hợp với từng quy mô khách.

Task 4 – Chỉ số chất lượng và đánh giá khách hàng

Người dùng muốn:

- Quan sát chất lượng dịch vụ của listing thông qua điểm đánh giá và mức độ hoạt động của review.
- Nhận diện khu vực hoặc nhóm listing có trải nghiệm tốt, ổn định, hoặc cần cải thiện.
- So sánh rating và số lượng review giữa các khu vực hoặc nhóm listing

Task 5 – Phân bố mức giá theo khu vực

Người dùng muốn hiểu:

- Mức giá thuê trung bình chênh lệch như thế nào giữa 5 quận của New York.
- Quận nào tập trung nhiều phòng giá rẻ, quận nào đắt đỏ nhất.

Task 6 – Bản đồ Giá Bất thường & Giá trị Thực

Người dùng muốn:

- Tìm kiếm các listing bị gán cờ ngoại lệ (**price_is_outlier = True**) để xem chúng tập trung ở đâu.
- Nhận diện các "món hời" (giá dưới mức trung vị nhưng điểm đánh giá lại cực cao) trong cùng một khu vực/loại phòng.

Task 7 – Hiệu quả Chi phí lưu trú

Người dùng muốn hiểu:

- Khu vực nào mang lại "giá trị tốt nhất" tính trên đầu người (**Price / Accommodates**).
- Chi phí bình quân đầu người thay đổi ra sao khi quy mô **nhóm khách tăng lên**.

Task 8 – Phân tích Mùa vụ và Cơ hội Đặt phòng

Người dùng muốn:

- Quan sát tỷ lệ lấp đầy thay đổi như thế nào theo các tháng trong năm.
- Nhận diện xem ràng buộc đêm tối thiểu (**minimum_nights**) có làm giảm cơ hội tiếp cận phòng của khách thuê vào mùa cao điểm không.

Task 9 – Phân tích Danh mục Chủ nhà

Người dùng muốn hiểu:

- Mức độ chuyên nghiệp hóa của thị trường (chủ nhà sở hữu nhiều listing vs. cá nhân lẻ tẻ).
- So sánh lợi thế cạnh tranh (mức độ lấp đầy, điểm đánh giá) của chủ nhà lớn so với chủ nhà cá nhân.

Task 10 – Trải nghiệm khách hàng

Người dùng muốn:

- Khai phá dữ liệu ngôn ngữ tự nhiên từ cột bình luận (**comments**).
- Nhận diện các từ khóa/chủ đề (sự sạch sẽ, vị trí, thái độ) xuất hiện nhiều nhất ở nhóm phòng điểm cao so với nhóm phòng điểm thấp.

2. Task Abstraction

2.1 Domain Task 1 – Thị trường và phân bố

Analyze

- Action: "Discover" → Target: "Distribution" Phát hiện phân bố giá theo khu vực
- Action: "Discover" → Target: "Outliers" Nhận diện các khu vực có giá bất thường

Search

- Action: "Explore" → Target: "Features" Khám phá các khu vực và loại phòng
- Action: "Locate" → Target: "Outliers" Xác định vị trí các khu vực giá cao/thấp

Query

- Action: "Compare" → Target: "Distribution" So sánh giá giữa các khu vực hoặc loại phòng
- Action: "Summarize" → Target: "Distribution" Tính giá trung bình theo khu vực

Summary

Discover + Explore + Locate + Compare + Summarize → Distribution + Outliers + Features

2.2 Domain Task 2 – Phân tích tỷ lệ lấp đầy theo thời gian

Analyze

- Action: "Discover" → Target: "Trends" Phát hiện xu hướng occupancy theo thời gian

Search

- Action: "Browse" → Target: "Trends" Duyệt dữ liệu theo timeline
- Action: "Locate" → Target: "Extremes" Xác định các tháng cao điểm / thấp điểm

Query

- Action: "Compare" → Target: "Trends" So sánh occupancy giữa các tháng
- Action: "Summarize" → Target: "Trends" Tính occupancy trung bình theo tháng

Summary

Discover + Browse + Locate + Compare + Summarize → Trends + Extremes

2.3 Domain Task 3 – Cấu trúc nguồn cung và sức chứa

Analyze

- Action: "Discover" → Target: "Distribution" Phát hiện phân bố nguồn cung theo room_type và accomodates.

- Action: "Discover" → Target: "Features" Nhận diện các đặc trưng từng khu vực theo cấu trúc loại phòng và sức chứa.

Search

- Action: "Explore" → Target: "Features" Khám phá sự khác biệt về nguồn cung giữa các nhóm vùng (borough) hoặc neighborhood.
- Action: "Locate" → Target: "Outliers" Xác định các khu vực có sức chứa lớn hoặc cấu trúc nguồn cung khác biệt.

Query

- Action: "Compare" → Target: "Distribution" So sánh phân bố room_type hoặc accommodates giữa các khu vực.
- Action: "Compare" → Target: "Dependency" So sánh mối quan hệ giữa sức chứa (accommodates) và giá (price).
- Action: "Summarize" → Target: "Distribution" Tính số lượng listing, sức chứa trung bình.

Summary

Discover + Explore + Locate + Compare + Summarize → Distribution + Features + Outliers + Dependency

2.4 Domain Task 4 – Chỉ số chất lượng và đánh giá khách hàng

Analyze

- Action: "Discover" → Target: "Distribution"
Phát hiện phân bố điểm đánh giá giữa các nhóm listing hoặc khu vực.
- Action: "Discover" → Target: "Outliers"
Nhận diện các listing hoặc khu vực có rating quá cao hoặc quá thấp.

Search

- Action: "Explore" → Target: "Features"
Khám phá các tín hiệu chất lượng theo room_type, neighbourhood_group_cleansed, hoặc neighbourhood_cleansed.
- Action: "Locate" → Target: "Outliers"
Xác định các khu vực có rating thấp bất thường hoặc số lượng review quá thấp/cao.

Query

- Action: "Compare" → Target: "Distribution"
So sánh phân bố rating giữa các khu vực hoặc các loại phòng.
- Action: "Compare" → Target: "Dependency"
So sánh mối quan hệ giữa review_scores_rating và number_of_reviews hoặc reviews_per_month.

- Action: "Summarize" → Target: "Distribution"
Tính rating trung bình hoặc số review trung bình theo khu vực / loại phòng.

Summary

Discover + Explore + Locate + Compare + Summarize → Distribution + Outliers + Features + Dependency

2.5 Domain Task 5– Phân bố giá theo khu vực

Analyze

- Action: "Discover" → Target: "Distribution" Phát hiện sự phân bố mức giá trên toàn bộ 5 quận.

Search

- Action: "Explore" → Target: "Features" Khám phá đặc trưng về giá trị bất động sản của từng khu vực.
- Action: "Locate" → Target: "Extremes" Xác định vị trí của các quận đắt đỏ nhất và rẻ nhất.

Query

- Action: "Compare" → Target: "Distribution" So sánh sự chênh lệch và khoảng biến thiên giá giữa các quận.
- Action: "Summarize" → Target: "Distribution" Tính toán mức giá trung bình/trung vị theo từng quận.

Summary Discover + Explore + Locate + Compare + Summarize → Distribution + Features + Extremes

2.6 Domain Task 6 – Bản đồ giá bất thường và giá trị thực

Analyze

- Action: "Discover" → Target: "Outliers" Phát hiện các listing có mức giá và chất lượng bất thường.

Search

- Action: "Explore" → Target: "Features" Khám phá sự phân bố không gian của các "món hời" trên bản đồ.
- Action: "Locate" → Target: "Outliers" Xác định chính xác vị trí các listing có giá trị thực vượt trội.

Query

- Action: "Compare" → Target: "Dependency" So sánh tương quan giữa mức giá và điểm đánh giá để tìm ra độ lệch.

Summary Discover + Explore + Locate + Compare → Outliers + Features + Dependency

2.7 Domain Task 7 – Hiệu quả chi phí lưu trú

Analyze

- Action: "Discover" → Target: "Dependency" Phát hiện mối quan hệ phụ thuộc giữa sức chứa (quy mô khách) và biến động chi phí bình quân.

Search

- Action: "Explore" → Target: "Features" Khám phá xu hướng thay đổi giá khi số lượng người lưu trú thay đổi.

Query

- Action: "Compare" → Target: "Distribution" So sánh chi phí bình quân đầu người giữa các khu vực.
- Action: "Compare" → Target: "Dependency" So sánh sự tối ưu chi phí giữa các nhóm quy mô khách khác nhau.
- Action: "Summarize" → Target: "Distribution" Tính toán chi phí đầu người trung bình theo quy mô và khu vực.

Summary Discover + Explore + Compare + Summarize → Dependency + Features + Distribution

2.8 Domain Task 8 – Phân tích mùa vụ và cơ hội đặt phòng

Analyze

- Action: "Discover" → Target: "Trends" Phát hiện xu hướng lấp đầy theo mùa vụ.
- Action: "Discover" → Target: "Dependency" Phát hiện mối quan hệ giữa chính sách `minimum_nights` và tỷ lệ lấp đầy.

Search

- Action: "Browse" → Target: "Trends" Duyệt dữ liệu lấp đầy dọc theo trục thời gian (timeline).
- Action: "Locate" → Target: "Extremes" Xác định chính xác các tháng cao điểm (cháy phòng) và thấp điểm.

Query

- Action: "Compare" → Target: "Trends" So sánh tỷ lệ lấp đầy giữa các tháng.

- Action: "Compare" → Target: "Dependency" Đối chiếu tỷ lệ lấp đầy giữa nhóm phòng có **minimum_nights** ngắn và dài.

Summary Discover + Browse + Locate + Compare → Trends + Extremes + Dependency

2.9 Domain Task 9 – Phân tích danh mục chủ nhà

Analyze

- Action: "Discover" → Target: "Dependency" Phát hiện mối quan hệ giữa quy mô danh mục của chủ nhà và hiệu suất kinh doanh (occupancy & rating).

Search

- Action: "Explore" → Target: "Features" Khám phá đặc trưng của nhóm listing thuộc quyền sở hữu của các chủ nhà sở hữu nhiều phòng.

Query

- Action: "Compare" → Target: "Distribution" So sánh phân bố điểm đánh giá và tỷ lệ lấp đầy giữa nhóm chủ nhà lớn và chủ nhà nhỏ lẻ.
- Action: "Summarize" → Target: "Distribution" Tính trung bình điểm đánh giá và lấp đầy theo phân loại quy mô chủ nhà.

Summary Discover + Explore + Compare + Summarize → Dependency + Features + Distribution

2.10 Domain Task 10 – Trải nghiệm khách hàng

Analyze

- Action: "Discover" → Target: "Features" Phát hiện các chủ đề và từ khóa (keywords) nổi bật phản ánh trải nghiệm khách hàng.

Search

- Action: "Explore" → Target: "Features" Khám phá ngôn ngữ và ngữ cảnh mà khách hàng sử dụng khi mô tả các nhóm listing khác nhau.

Query

- Action: "Compare" → Target: "Distribution" So sánh tần suất xuất hiện của các từ khóa tích cực/tiêu cực giữa nhóm phòng điểm cao và điểm thấp.
- Action: "Summarize" → Target: "Features" Tổng hợp thành tập hợp các từ vựng cốt lõi nhất.

Summary Discover + Explore + Compare + Summarize → Features + Distribution

Appendix - Bảng Profiling Chi Tiết

Phụ lục này tập hợp các bảng chi tiết đã được lược khỏi phần profiling chính để giữ mạch trình bày ngắn gọn.

A.1 Bảng kiểm tra tính hợp lệ (regex/rule)

Dataset	Field	Rule	Valid	Invalid	Validity (%)
listings_raw	price	numeric_string_currency	21,415	0	100.00
listings_standardized	price	positive_numeric	21,415	0	100.00
listings_standardized	review_scores_rating	rating_0_100	25,007	0	100.00
listings_standardized	latitude	lat_nyc	36,353	0	100.00
listings_standardized	longitude	lon_nyc	36,353	0	100.00
calendar_raw	date	date_yyyy_mm_dd	13,268,858	0	100.00
calendar_raw	available	available_tf	13,268,858	0	100.00
reviews_raw	date	date_yyyy_mm_dd	1,000,870	0	100.00

A.2 Bảng thống kê mô tả số (raw selected)

Dataset	Field	Min	Max	Mode	AVG	Median
listings_raw_selected	price	9	50,138	150	519.6229	154

Dataset	Field	Min	Max	Mode	AVG	Median
listings_raw_selected	review_scores_rating	0	5	5	4.7213	4.86
listings_raw_selected	availability_365	0	365	0	165.38	156
calendar_raw_selected	minimum_nights	1	1,124	30	29.3969	30
calendar_raw_selected	maximum_nights	1	2,147,483,647	1125	647,712.2799	365

A.3 Bảng hai chiều theo từng thuộc tính (raw)

Dataset	Field	Null	Missing	Actual	Completeness (%)	Cardinality	Uniqueness (%)	Distinctness (%)
listings	id	0	0	36,353	100.00	36,353	100.00	100.00
listings	price	14,938	14,938	21,415	58.91	1,106	5.16	3.04
listings	reviews_per_month	11,346	11,346	25,007	68.79	825	3.30	2.27
listings	review_scores_rating	11,346	11,346	25,007	68.79	161	0.64	0.44
calendar	listing_id	0	0	13,268,858	100.00	36,353	0.27	0.27
calendar	price	13,268,858	13,268,858	0	0.00	0	0.00	0.00
calendar	minimum_nights	0	0	13,268,858	100.00	155	0.00	0.00
calendar	maximum_nights	0	0	13,268,858	100.00	287	0.00	0.00
reviews	listing_id	0	0	1,000,870	100.00	25,007	2.50	2.50

Dataset	Field	Null	Missing	Actual	Completeness (%)	Cardinality	Uniqueness (%)	Distinctness (%)
reviews	comments	257	257	1,000,613	99.97	960,213	95.96	95.94

A.4 Bảng mẫu định dạng phổ biến (top patterns)

Dataset	Field	Pattern	Count	Pct
listings	room_type	ssssss ssss-sss	19,427	53.44
listings	room_type	ssssss ssss	16,306	44.85
calendar	date	dddd-dd-dd	13,268,858	100.00
calendar	available	s	13,268,858	100.00
reviews	date	dddd-dd-dd	1,000,870	100.00
reviews	comments	sssss ssss-	1,965	0.20
reviews	comments	-	1,836	0.18

A.5 Bảng hồ sơ ngoại lệ (IQR)

Field	Lower	Upper	Outlier count	Outlier pct
listings.price (clean)	-178.5	537.5	1,385	6.47
calendar.minimum_nights (raw)	30	30	2,532,685	19.09
calendar.maximum_nights (raw)	-775	2,265	6,553	0.05

A.6 Bảng phân tích giá trị thiếu

Dataset	Field	Missing count	Missing pct	Missing type
listings	price	14,938	41.09	MCAR/technical
listings	reviews_per_month	11,346	31.21	MAR/semantic

Dataset	Field	Missing count	Missing pct	Missing type
listings	review_scores_rating	11,346	31.21	MAR/semantic
calendar	price	13,268,858	100.00	MCAR/source-missing
reviews	comments	257	0.03	MCAR/empty-text

A.7 Bảng ví dụ bản ghi lỗi **minimum_nights > maximum_nights**

listing_id	date	minimum_nights	maximum_nights
6601284	2025-11-14	30	5
6601284	2025-11-15	30	4
6601284	2025-11-16	30	3
6601284	2025-11-17	30	2
6601284	2025-11-26	30	7

A.8 Bảng quyết định làm sạch (cleaning decision)

Dataset	Vấn đề phát hiện	Quyết định làm sạch	Lý do quyết định	Tác động đến phân tích
listings	price thiếu 41.09% và có bản ghi không đạt điều kiện cốt lõi	Loại các dòng thiếu price hoặc price <= 0 ; loại bản ghi thiếu khóa/categorical cốt lõi; giữ outlier bằng cờ price_is_outlier	price là measure chính của Task 1, cần dữ liệu hợp lệ; giữ outlier để không mất tín hiệu thị trường cao cấp	Tăng độ tin cậy phân tích giá và không gian, đồng thời vẫn hỗ trợ phân tích nhạy cảm với outlier
listings	reviews_per_month , review_scores_rating thiếu theo ngữ nghĩa (listing chưa có review)	Giữ missing, không nội suy cưỡng bức; diễn giải theo điều kiện number_of_reviews	Missing mang ý nghĩa nghiệp vụ, không phải lỗi thu thập thuần túy	Tránh sai lệch khi so sánh chất lượng review giữa các nhóm listing

Dataset	Vấn đề phát hiện	Quyết định làm sạch	Lý do quyết định	Tác động đến phân tích
calendar	Khóa logic trùng (listing_id , date) và bản ghi availability không hợp lệ	Loại trùng theo khóa logic; loại dòng thiếu khóa/ngày; loại availability không hợp lệ	Đảm bảo mức độ chi tiết listing-ngày nhất quán cho chuỗi thời gian	Ổn định phép tổng hợp theo tháng và tránh đếm trùng occupancy
calendar	Mâu thuẫn minimum_nights > maximum_nights	Gán NaN cho cặp nights mâu thuẫn thay vì loại toàn dòng	Giữ lại thông tin availability/time còn hợp lệ, chỉ vô hiệu phần constraint sai	Giảm mất dữ liệu không cần thiết cho Task 2
calendar	price thiếu 100%	Không dùng calendar.price cho phân tích giá theo thời gian; chuyển trọng tâm Task 2 sang khả dụng/lấp đầy	Không có tín hiệu giá để ước lượng đáng tin cậy	Task 2 được điều chỉnh phạm vi: giữ xu hướng lấp đầy theo thời gian, loại xu hướng giá theo thời gian
reviews	Thiếu/không hợp lệ ở listing_id , date , comments ; tồn tại trùng toàn dòng	Loại trùng toàn dòng; loại bản ghi thiếu khóa/ngày/comments; loại comments rỗng	Bảo toàn toàn vẹn khóa và chất lượng văn bản tối thiểu cho khai thác nội dung	Tăng độ tin cậy cho thống kê theo thời gian và phân tích text
Liên bảng	Bản ghi mồ côi trong calendar/reviews không tồn tại trong listings_clean	Loại orphan theo tập valid_listing_ids từ listings_clean	Đảm bảo toàn vẹn tham chiếu 1-n giữa bảng thực thể và bảng sự kiện	Tránh sai lệch khi join và tổng hợp cross-table

A.9 Bảng tổng quan chỉ số của file GeoJSON

Chỉ số	Giá trị
Số feature không gian (n_features)	233
Số neighbourhood duy nhất (n_neighbourhood)	230

Chỉ số	Giá trị
Số neighbourhood_group duy nhất (n_neighbourhood_group)	5

A.10 Bảng kiểm tra tọa độ và bbox

Chỉ số	Giá trị
latitude min	40.50456
latitude max	40.91114683573623
longitude min	-74.251907
longitude max	-73.71365
Tỷ lệ bản ghi nằm trong bbox NYC mở rộng (lat [40.4, 41.0], lon [-74.3, -73.6])	100.00%

A.11 Bảng coverage join theo neighbourhood

Chỉ số	Giá trị
Số khu vực trong listings_clean	222
Số khu vực trong geojson	230
Khu vực chỉ có trong listings_clean	0
Khu vực chỉ có trong geojson	8

Các khu vực chỉ có trong GeoJSON (không xuất hiện trong listings_clean): Bloomfield, Charleston, Glen Oaks, New Dorp, New Springville, Pleasant Plains, Port Ivory, Richmondtown.

A.12 Bảng quy mô giảm sau làm sạch

Bảng	Raw rows	Clean rows	Giảm	Tỷ lệ giảm
Listings	36,353	21,415	14,938	41.09%
Calendar	13,268,858	7,816,487	5,452,371	41.09%
Reviews	1,000,870	787,325	213,545	21.34%

A.13 Bảng toàn vẹn khóa sau làm sạch

Chỉ số	Giá trị
listings_clean.id cardinality	21,415
calendar_clean.listing_id cardinality	21,415
reviews_clean.listing_id cardinality	14,999

A.14 Bảng occupancy theo tháng

Tháng	Tỷ lệ lấp đầy (%)
1	20.56
2	21.97
3	21.02
4	21.10
5	29.07
6	28.41
7	27.95
8	36.98
9	37.23
10	37.14
11	51.66
12	35.86

A.15 Phân loại toàn bộ 28 thuộc tính được phân tích

Bảng dưới đây là danh sách phân rã và gán vai trò chi tiết cho toàn bộ 28 thuộc tính được sử dụng (bao gồm các trường gốc và trường dẫn xuất đã chốt sau làm sạch), phục vụ cho quá trình xây dựng Dashboard trực quan hóa.

STT	Dataset	Tên cột (Attribute)	Nhóm thuộc tính	Kiểu dữ liệu (Q/O/C)	Vai trò phân tích (Analytical Role) chi tiết
1	listings	id	Khóa (Key/PK)	Categorical (C)	Định danh duy nhất căn hộ, dùng đếm tổng cung (Total Listings).
2	listings	host_id	Khóa ngoại (Key/FK)	Categorical (C)	Định danh chủ nhà, dùng đếm số lượng chủ nhà hoặc nhóm chủ tập đoàn.
3	listings	neighbourhood _group_cleans ed	Không gian	Categorical (C)	Phân nhóm tổng hợp cấp Quận (Borough), làm filter hoặc group by cho Bar/Boxplot.
4	listings	neighbourhood _cleansed	Không gian	Categorical (C)	Phân nhóm tổng hợp cấp Phường/Khu vực nhỏ, là khóa Join với mảng GeoJSON.
5	listings	latitude	Tọa độ điểm	Quantitative (Q)	Trục Y không gian, dùng thả ghim lên bản đồ (Point Map).
6	listings	longitude	Tọa độ điểm	Quantitative (Q)	Trục X không gian, dùng thả ghim lên bản đồ (Point Map).

STT	Dataset	Tên cột (Attribute)	Nhóm thuộc tính	Kiểu dữ liệu (Q/O/C)	Vai trò phân tích (Analytical Role) chi tiết
7	listings	room_type	Phân loại nhà	Categorical (C)	Gom cụm so sánh cơ cấu thị trường (Entire home vs Private room).
8	listings	price	Tài chính	Quantitative (Q)	Đo lường mức giá, tìm phân bố giá trị trung vị và ngoại lệ qua Chart.
9	listings	availability_365	Mức sẵn sàng	Quantitative (Q)	Đo lường tổng số ngày trống trong năm tiếp theo.
10	listings	accommodates	Quy mô nhà	Quantitative (Q)	Đo sức chứa tối đa của phòng, dùng đánh giá quy mô tệp khách phù hợp.
11	listings	number_of_reviews	Mức độ hoạt động	Quantitative (Q)	Đếm tổng số nhận xét, đo độ "hot" và mật độ khách thuê thực tế.
12	listings	reviews_per_month	Mức độ hoạt động	Quantitative (Q)	Tốc độ tăng trưởng mức độ nhận xét bình quân trên tháng.
13	listings	review_scores_rating	Tín hiệu chất lượng	Quantitative (Q)	Chấm điểm sự hài lòng trung bình để nhận diện rủi ro /

STT	Dataset	Tên cột (Attribute)	Nhóm thuộc tính	Kiểu dữ liệu (Q/O/C)	Vai trò phân tích (Analytical Role) chi tiết
					chất lượng phòng.
14	calendar	listing_id	Khóa ngoại (Key/FK)	Categorical (C)	Khóa liên kết dữ liệu chuỗi thời gian về đúng căn nhà mục tiêu.
15	calendar	date	Thời gian	Ordinal (O)	Dòng mốc thời gian chi tiết của sự kiện.
16	calendar	available	Trạng thái gốc	Categorical (C)	Ký tự gốc (t/f) biểu thị nhà có ai đặt hay chưa.
17	calendar	price	Tài chính	Quantitative (Q)	(Vô hiệu hóa do missing 100%) Gốc là đo giá biến động theo thời gian.
18	calendar	minimum_nights	Quy định	Quantitative (Q)	Ràng buộc số đêm thuê tối thiểu của chủ nhà theo mùa.
19	calendar	maximum_nights	Quy định	Quantitative (Q)	Ràng buộc số đêm thuê tối đa của chủ nhà theo mùa.
20	calendar	is_available	Trạng thái phòng	Categorical (C)	Trường dẫn xuất T/F quy chuẩn tỷ lệ phòng trống.

STT	Dataset	Tên cột (Attribute)	Nhóm thuộc tính	Kiểu dữ liệu (Q/O/C)	Vai trò phân tích (Analytical Role) chi tiết
21	calendar	is_booked	Trạng thái phòng	Quantitative (Q)	Trường dẫn xuất nhị phân (0/1) dùng tính trực tiếp % lấp đầy (Occupancy) khi đo mean().
22	calendar	year	Thời gian tổng hợp	Ordinal (O)	Lọc hoặc phân rã biểu đồ đường theo các năm riêng biệt.
23	calendar	month	Thời gian tổng hợp	Ordinal (O)	Trục X chính giúp hiện thực hóa User Story về Tính Mùa Vụ.
24	reviews	listing_id	Khóa ngoại (Key/FK)	Categorical (C)	Câu nối ghép nội dung review về đối tượng căn nhà.
25	reviews	date	Thời gian đánh giá	Ordinal (O)	Dùng để dò mật độ khách đến lưu trú theo các mốc thời gian cũ.
26	reviews	comments	Nội dung Text	Categorical (C)	Đọc, dò mẫu từ khoá cảm xúc, hỗ trợ đánh giá chất lượng thay vì chỉ có số.
27	geojson	neighbourhood	Không gian vùng	Categorical (C)	Key không gian để nối màu mức giá/số nhà vào

STT	Dataset	Tên cột (Attribute)	Nhóm thuộc tính	Kiểu dữ liệu (Q/O/C)	Vai trò phân tích (Analytical Role) chi tiết
					bản đồ Choropleth.
28	geojson	neighbourhood_group	Nhóm vùng rộng	Categorical (C)	Cung cấp ranh giới cấp Borough to nhất cho tổng quan bản đồ.