

Thống kê dữ liệu

- **Null:** đếm số lượng dữ liệu null/ hoặc trống
- **Actual:** đếm số dữ liệu có giá trị
- **Completeness:** tính bằng $\text{actual}/\text{số dòng}$
- **Cardinality:** đếm số giá trị phân biệt
- **Uniqueness:** tính bằng $\text{cardinality}/\text{số dòng}$
- **Distinctness:** tính bằng $\text{cardinality}/\text{actual}$

Field Name	NULL	Actual	Completeness	Cardinality	Uniqueness	Distinctness
OrderID	0	24	100.00%	22	91.67%	91.67%
CustomerName	1	23	95.83%	21	87.50%	91.30%
Product	1	23	95.83%	21	87.50%	91.30%
Category	0	24	100.00%	8	33.33%	33.33%
Price	1	23	95.83%	18	75.00%	78.26%
Quantity	0	24	100.00%	8	33.33%	33.33%
OrderDate	0	24	100.00%	22	91.67%	91.67%
PaymentStatus	1	23	95.83%	6	25.00%	26.09%
ShippingCity	0	24	100.00%	23	95.83%	95.83%

Field Name	Regex	Validity	Min	Max	Mode	AVG	Median
OrderID	\d+\.\d+	100%	101	124	101	112.21	112.50
CustomerName	[\s a-zA-Z]	95.7%					
Product	[\w\s]	100%					
Category	\w	100%					
Price	\d	87.0%	-50	50000	20	2667.62	150
Quantity	\d	87.5%	-1	1000000	1	43479.89	1
OrderDate	\d{4}-\d{2}-\d{2}	91.7%	01/18/2023	27-01-2023	2023-01-15		
PaymentStatus	\w	95.8%					
ShippingCity	[\w\s]	100.0%					

Field Name	Data type	Top 5 patterns	Outliers IQR
OrderID	Decimal	sss.s	
CustomerName	String	ssss ssss : 21.7% sss ssss: 13.0% sssss ssss: 13.0% ssss sss: 8.7% sssss sssss: 8.7%	
Product	String	ssssss : 1.7% sssssss: 17.4% sssss: 13.0% ssss: 13.0% ssssssssss: 8.7%	
Category	String	sssssssssss :45.8% sssssssss: 33.3% ssssss :8.3% sssssss: 8.3% sssssssss :4.2%	
Price	Integer	ddd:39.1% dd:30.4% dddd:13.0% \$ddd: 4.3% ddddd: 4.3%	1200 50000
Quantity	Integer	d:79.2% ddd: 4.2% -d: 4.2% dd: 4.2% d.d: 4.2%	-1 4 10 1000000
OrderDate	Date	dddd-dd-dd: 91.7% dd/dd/dddd: 4.2% dd-dd-dddd: 4.2%	
PaymentStatus	String	ssss: 70.8% sssssss: 8.3% sssss: 8.3% sssssss: 4.2% ssssss: 4.2%	
ShippingCity	String	sssssss: 20.8% ssssss: 16.7% sss ssss: 12.5% sss sssssss: 8.3% ssss ssss: 8.3%	

Phân tích chất lượng dữ liệu dựa vào bảng thống kê

1. Giá trị không hợp lệ/ Sai định dạng

- **Price:**
 - Chứa ký tự không phải số: \$300, Free
 - Giá trị âm: -50
 - Giá trị bất thường: 50000 => **Giá cáp USB quá cao?**
- **Quantity:**
 - Không phải số nguyên: two, 1.5
 - Giá trị âm: -1 => **Số lượng âm có phải trả hàng không? Hoặc lỗi dữ liệu?**
 - Giá trị cực đại bất thường: 1000000 => **Số lượng quá lớn?**
- **OrderDate:**
 - Định dạng không thống nhất: 2023-01-15 vs 01/18/2023 vs 27-01-2023
 - Ngày không hợp lệ: **2023-02-30**
 - Ngày trong tương lai: 2025-01-01 => **Dataset 2023?**
- **PaymentStatus:**
 - Sai chính tả / không chuẩn:
 - Payed/ Paid => **Cùng loại?**
 - Error và N/A => **Chưa thanh toán được, có nên chuyển thành status khác?**
- **Category:**
 - Sai chính tả: Furnitur
- **ShippingCity:**
 - Không chuẩn hoá:
 - New York
 - NYC
 - new york

2. Ngoại lệ và bất thường => phân tích thêm

- **Duplicate record:** OrderID 116.0 xuất hiện 2 lần giống hệt nhau
- **Duplicate OrderID:** OrderID 101.0 xuất hiện 2 lần
- **CustomerName chứa email:** peter@example.com
- **Price = 0 / Free**
- **Quantity rất lớn:** 1.000.000

Xử lý làm sạch dữ liệu

1. Chuẩn hoá định dạng **Price, Quantity, OrderDate, PaymentStatus, Category, ShippingCity**
2. Xử lý duplicate (OrderID 101 & 116)

Phân loại dữ liệu khuyết và xử lý

Cột	Số khuyết	Vị trí (OrderID)	Loại khuyết	Xử lý
CustomerName	1	110	MCAR	Xóa dòng
Product	1	112	MAR	Xóa dòng
Price	1	103	MCAR	Điền trung bình

Dữ liệu sau khi làm sạch

OrderID	CustomerName	Product	Category	Price	Quantity	OrderDate	PaymentStatus	ShippingCity
101	John Doe	Laptop	Electronics	1200	1	1/15/2023	Paid	New York
102	Jane Smith	Smartphone	Mobile	800	2	1/16/2023	Paid	Los Angeles
103	Alice Brown	Headphones	Electronics	300	1	1/17/2023	Pending	Chicago
104	Bob White	Monitor	Electronics	300	1	1/18/2023	Paid	Houston
105	Carol Green	Mouse	Accessories	25	2	1/19/2023	Paid	Phoenix
106	Dave Black	Keyboard	Accessories	45	1	1/20/2023	Refunded	San Antonio
108	Eva Blue	USB Cable	Accessories	35	10	1/22/2023	Paid	San Diego
109	Frank Red	Charger	Electronics	20	1	1/22/2023	Unpaid	Dallas
110	Grace Hall	Webcam	Electronics	60	1	1/25/2023	Paid	Austin
111	Henry Ford	Tablet	Electronics	300	1	1/25/2023	Paid	San Jose
112	Ivy Rose	Printer	Office	150	1	1/27/2023	Paid	Jacksonville
113	Jack Ryan	Software Trial	Software	0	1	1/28/2023	Unknown	San Francisco
115	Kelly King	Speaker	Electronics	0	1	1/29/2023	Error	Columbus
116	Liam Scott	Chair	Furniture	200	4	1/30/2023	Paid	Fort Worth
118	Mia Young	Desk	Furniture	350	1	2/1/2023	Paid	New York
119	Noah Allen	Lamp	Furniture	40	2	2/2/2023	Paid	Charlotte
120	Olivia King	Sofa	Furniture	800	1	2/2/2023	Pending	Seattle
121	Peter	Bed	Furniture	500	1	2/4/2023	Paid	Denver
122	Quinn Lee	Pillow	Furniture	20	1	2/5/2023	Paid	Washington
123	Rachel Green	Curtains	Furniture	60	2	2/6/2023	Paid	Boston
124	Sam White	Rug	Furniture	0	1	2/7/2023	Paid	Nashville

Data abstraction

- **Data type:** item - attribute
- **Dataset type:** table
- **Dataset availability:** dynamic
- **Item semantic:** mỗi dòng là một đơn đặt hàng

Attribute Name	Type (C,O,Q)	Key/Value	Direction	Hierarchical	Continuous/ Discrete	Semantic
OrderID	C	K			Discrete	Mã đặt hàng
CustomerName	C	V			Discrete	Tên khách hàng
Product	C	V			Discrete	Tên sản phẩm
Category	C	V			Discrete	Loại sản phẩm
Price	Q	V	Sequential		Continuous	Giá
Quantity	Q	V	Sequential		Discrete	Số lượng
OrderDate	Q	V	Sequential	D – M – Y	Continuous	Ngày đặt
PaymentStatus	C	V			Discrete	Trạng thái thanh toán
ShippingCity	C	V			Discrete	Thành phố giao

Domain-task

1. User story formula

- Xác định vai trò: **Quản lý cửa hàng**, quản lý chuỗi cung ứng, vận chuyển,
- Xác định mục tiêu/ vấn đề: áp dụng chương trình giảm giá 30–50% hoặc trả hàng cho nhà cung cấp để giảm tồn kho ế và cải thiện dòng tiền.
- Xác định insight/phân tích: biết top 10 sản phẩm (Product/SKU) bán chậm nhất (doanh thu thấp nhất hoặc Quantity bán ra thấp nhất) theo từng ShippingCity và theo Category trong 2 tháng gần nhất,
- Kết hợp thành câu hỏi:

As a Quản lý cửa hàng (Store Manager),

I want to biết top 10 sản phẩm (Product/SKU) bán chậm nhất (doanh thu thấp nhất hoặc Quantity bán ra thấp nhất) theo từng ShippingCity và theo Category trong 2 tháng gần nhất,

so that I can áp dụng chương trình giảm giá 30–50% hoặc trả hàng cho nhà cung cấp để giảm tồn kho ế và cải thiện dòng tiền.

2. 5-whys drill-down

Surface Problem: Có nhiều đơn hàng có Price = 0 hoặc giá trị bất thường (0, lỗi nhập liệu), dẫn đến báo cáo doanh thu bị sai lệch.

Why 1: Tại sao có nhiều đơn hàng Price = 0? → Vì các đơn này chủ yếu thuộc Category Software (Software Trial) và một số Electronics (Speaker) với PaymentStatus là Error hoặc Unknown.

Why 2: Tại sao các đơn Trial/Error lại có Price = 0? → Vì hệ thống nhập liệu mặc định Price = 0 cho các đơn hàng thử nghiệm hoặc đơn bị lỗi thanh toán, mà không có bước kiểm tra tự động.

Why 3: Tại sao hệ thống không kiểm tra và gán giá trị đúng? → Vì phần lớn các đơn hàng này tập trung trong tháng 1–2/2023 (OrderDate), có thể trùng với giai đoạn chạy chương trình thử nghiệm sản phẩm hoặc import dữ liệu thử nghiệm.

Why 4: Tại sao chương trình thử nghiệm hoặc import dữ liệu lại dẫn đến Price = 0 ở một số khu vực? → Vì các đơn Trial/Error tập trung ở một số ShippingCity miền Tây/Nam Mỹ (San Francisco, San Diego, Jacksonville, Columbus...), có thể do chiến dịch thử nghiệm được triển khai chủ yếu ở khu vực này.

Why 5 (Root Cause): Tại sao chiến dịch thử nghiệm/import dữ liệu không được xử lý giá trị Price đúng cách? → Vì quy trình nhập liệu và kiểm soát chất lượng dữ liệu thiếu bước validation tự động cho các loại đơn hàng đặc biệt (Trial, Test, Error), dẫn đến dữ liệu bị sai lệch và ảnh hưởng đến báo cáo doanh thu thực tế.

Deep Question: “Giá trị doanh thu bị mất do các đơn hàng Price = 0 hoặc bất thường phân bổ như thế nào theo Category, PaymentStatus và ShippingCity, đặc biệt trong giai đoạn tháng 1–2/2023, và nguyên nhân gốc rễ có phải từ thiếu validation tự động cho đơn Trial/Error trong quy trình nhập liệu không?”

3. Inverted pyramid

Lớp Top (5–10 giây glance – Câu hỏi cấp cao nhất):

- Doanh thu tổng và % hoàn thành mục tiêu tháng 1–2/2023 là bao nhiêu?
- Tỷ lệ đơn hàng không hoàn tất (Pending + Unpaid + Refunded + Error) là bao nhiêu %?
- Có cảnh báo nào khẩn cấp (ví dụ: 15% đơn hàng Price = 0)?

Lớp Middle (Context & Trends – Câu hỏi cung cấp ngữ cảnh):

- Doanh thu phân bổ theo Category và ShippingCity như thế nào?
- Xu hướng doanh thu theo tuần/tháng trong quý 1/2023 có thay đổi gì nổi bật?
- Top 5 ShippingCity đóng góp doanh thu cao nhất và bottom 5 là gì?

Lớp Bottom (Details on demand – Câu hỏi chi tiết để hành động):

- Danh sách chi tiết các đơn hàng có Price = 0 hoặc bất thường theo Product, Category, PaymentStatus, ShippingCity và OrderDate là gì?
- Các đơn hàng Pending/Refunded/Error tập trung ở ShippingCity nào và Category nào, để có thể kiểm tra và hỗ trợ khách hàng?

4. 3-Tier logic chain

KPI 1: Total Revenue (Doanh thu tổng)

Tier 1 – Top (What – KPIs nhanh)

- Tổng doanh thu tháng 1–2/2023: X USD
- % thay đổi MoM (tháng 2 so với tháng 1): +Y%
- % hoàn thành mục tiêu (nếu có): Z%
- Alert: 15% đơn hàng Price = 0 → mất mát doanh thu ước tính W USD

Tier 2 – Middle (Why / Context & Trends)

- Doanh thu theo Category: Electronics chiếm bao nhiêu %? Furniture chiếm bao nhiêu %?
- Doanh thu theo ShippingCity: Top 3 thành phố đóng góp cao nhất là gì?

- Xu hướng doanh thu theo tuần trong tháng 2 (có ngày nào đột biến không?)
- So sánh top 3 sản phẩm vs bottom 3 sản phẩm (theo $Total = Price \times Quantity$)

Tier 3 – Bottom (Details on demand)

- Bảng chi tiết: OrderID, Product, Category, Price, Quantity, Total, OrderDate, PaymentStatus, ShippingCity
- Filter: Chỉ xem đơn hàng Price = 0 hoặc bất thường để kiểm tra nguyên nhân
- Danh sách khách hàng có tổng giá trị đơn hàng cao nhất (sum Total theo CustomerName)

Abstraction-task

1. Quản lý cửa hàng (Store Manager) muốn biết **top 10 sản phẩm (Product/SKU) bán chậm nhất** (doanh thu thấp nhất hoặc Quantity bán ra thấp nhất) **theo từng ShippingCity và theo Category trong 2 tháng gần nhất**, để áp dụng chương trình giảm giá 30–50% hoặc trả hàng cho nhà cung cấp để giảm tồn kho ế và cải thiện dòng tiền.

Abtraction task:

- Analyze
 - **Action:** Consume > discover → **Target:** all data > trends (*khám phá xu hướng tăng/ giảm của sản phẩm*)
 - **Action:** Consume > present → **Target:** attributes many > dependency (*trình bày kết quả top 10 sản phẩm bán chạy theo tháng*)
- Search
 - **Action:** Browse → **Target:** attributes many (*duyệt qua các nhóm ShippingCity/ Category để tìm top 10*)
- Query
 - **Action:** Identify → **Target:** all data > outliers
 - **Action:** Compare → **Target:** attributes many > similarity
 - **Action:** Summarize → **Target:** all data > Features